

Projet Big Data – Analyse des Infrastructures de Recharge pour Véhicules Électriques

Groupe 8 – Mathis LETELLIER, Joas Erwen MVOUMA EKEMI, Victor ROUSSEL

11 juin 2026

Contents

1	Introduction	2
2	Fonctionnalité 1 – Description et nettoyage des données	3
2.1	Description du jeu de données brut	3
2.1.1	Taux de valeurs manquantes après nettoyage	3
2.2	Statistiques descriptives univariées	3
2.3	Stratégies de nettoyage appliquées	4
2.4	Résultat du nettoyage	5
3	Fonctionnalité 2 – Visualisation graphique	6
3.1	Parts de marché des opérateurs	6
3.2	Répartition des puissances par type d'implantation	7
3.3	Évolution temporelle des déploiements	7
3.4	Maturité technologique des prises	7
4	Fonctionnalité 4 – Étude des corrélations	9
4.1	Matrice de corrélation	9
5	Conclusion	10

1 Introduction

Ce rapport présente l'analyse complète du jeu de données national des **Infrastructures de Recharge pour Véhicules Électriques (IRVE)**, publié en open data sur data.gouv.fr.

L'objectif est de mettre en œuvre une chaîne complète de traitement : nettoyage, visualisation, analyse des corrélations et modélisation prédictive, à partir d'un fichier de **184 504 entrées brutes**.

2 Fonctionnalité 1 – Description et nettoyage des données

2.1 Description du jeu de données brut

Le fichier `IRVE.csv` contient **184 504 lignes** et **52 colonnes** couvrant les caractéristiques techniques, géographiques et opérationnelles de chaque point de charge (PDC).

Choix méthodologique : Avant tout nettoyage, nous avons réalisé un audit complet du jeu de données (taux de valeurs manquantes, types, distributions). Cette étape préalable nous a permis de **justifier chaque décision de nettoyage** plutôt que d’appliquer des règles génériques. Le pipeline a été découpé en 4 étapes indépendantes avec sauvegarde intermédiaire (`.rds`) pour reprendre le traitement sans tout recalculer.

2.1.1 Taux de valeurs manquantes après nettoyage

Table 1: Top 15 des colonnes avec valeurs manquantes (après nettoyage)

Colonne	Taux NA (%)
tarif_kwh_clean	90.8
raccordement	42.5
date_mise_en_service	29.8
telephone_opérateur	7.3

Analyse : On distingue trois catégories de colonnes :

- **Très lacunaires (> 50%) :** `observations`, `tarification`, `num_pdl` — conservées mais exclues des analyses quantitatives.
- **Modérément incomplètes (10–50%) :** `date_mise_en_service`, `siren_amenageur` — traitées par imputation ou mise à NA selon le contexte.
- **Complètes (< 2%) :** `puissance_nominale`, coordonnées GPS — fiables pour les corrélations et la cartographie.

2.2 Statistiques descriptives univariées

Table 2: Statistiques descriptives des variables numériques clés

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
puissance_nominale	0	22	22	77.97	150	350
nbre_pdc	1	2	4	8.61	8	241




Figure 1: Distribution des puissances nominales (données nettoyées)

Observation : La distribution est fortement asymétrique à droite. La grande majorité des bornes délivrent **22 kW** (médiane — chargeurs AC standard de type 2), avec une minorité de bornes rapides DC (50–150 kW). Cette bimodalité est cohérente avec la réalité du parc IRVE français et confirme que l’imputation par la médiane était le choix adapté pour les valeurs manquantes.

2.3 Stratégies de nettoyage appliquées

Table 3: Pipeline de nettoyage en 4 étapes

Étape	Script	Actions principales	Stratégie clé
1	01_import_et_nettoyage.py	De-blon, encodage, valeurs aberrantes, booléens, métadonnées	Médiane pour puissance/nbre_pdc, 'Inconnu' pour texte
2	02_traitement_geo.R	Validation GPS, cohérence géographique, centroïdes	Suppression stricte si pas de GPS valide
3	03_traitement_tarifs.R	Normalisation tarification, regroupement en 3 classes	Imputation 'Non renseigné' si vide
4	04_traitement_horaires.R	Parsing et normalisation des plages horaires	NA si format non parseable

Choix architectural – Pipeline séquentiel avec checkpoints : Nous avons structuré le nettoyage en **4 scripts indépendants** orchestrés par `main.R`. Ce choix permet de reprendre le traitement à n’importe quelle étape sans tout recalculer (les `.rds` servent de points de sauvegarde). Sur un fichier de 123 Mo, cela réduit le temps de développement de plusieurs minutes à quelques secondes.

Choix méthodologique – Imputation vs Suppression : L’imputation par la **médiane** a été préférée à la suppression pour `puissance_nominale` et `nbre_pdc`. Supprimer ces lignes aurait réduit le jeu de données sans gain réel, car les autres attributs de ces bornes (localisation, opérateur, type de prise) restent exploitables. La médiane est robuste aux valeurs extrêmes, contrairement à la moyenne (distribution asymétrique confirmée par l’histogramme ci-dessus).

2.4 Résultat du nettoyage

Table 4: Bilan du pipeline de nettoyage

Indicateur	Valeur
Lignes initiales (IRVE.csv)	184 504
Lignes après nettoyage complet	70 394
Lignes supprimées au total	114 110
Colonnes initiales	52
Colonnes finales	38
Médiane <code>puissance_nominale</code>	22 kW

3 Fonctionnalité 2 – Visualisation graphique

3.1 Parts de marché des opérateurs




Figure 2: Top 10 des opérateurs – Répartition par modèle économique

3.2 Répartition des puissances par type d'implantation




Figure 3: Puissance nominale selon le lieu d'implantation

Analyse : Les stations dédiées à la recharge rapide concentrent logiquement les bornes ultra-rapides (150+ kW). Les parkings publics accueillent majoritairement des chargeurs standard 22 kW, cohérent avec des durées de stationnement longues (centres commerciaux, gares).

3.3 Évolution temporelle des déploiements

Analyse : La courbe de tendance (en rouge) révèle une accélération nette à partir de 2020, coïncidant avec les plans de relance post-Covid et les objectifs européens. La légère baisse en fin de courbe s'explique par des données partielles sur les mois les plus récents (mai 2026).

3.4 Maturité technologique des prises

Analyse : La prise **Type 2** domine largement, cohérent avec sa désignation comme standard européen obligatoire depuis 2014. La faible présence de CHAdeMO illustre le déclin de ce format japonais face au Combo CCS qui s'impose comme standard de la recharge rapide en Europe.




Figure 4: Dynamique de déploiement du réseau IRVE (2015–2026)




Figure 5: Répartition des types de prises sur le réseau IRVE

4 Fonctionnalité 4 – Étude des corrélations

4.1 Matrice de corrélation




Figure 6: Matrice de corrélation entre les variables numériques

Analyse : La matrice révèle les relations entre les variables numériques du jeu de données. Les corrélations significatives identifiées orienteront le choix des variables explicatives pour le modèle de prédiction de la puissance nominale (Fonctionnalité 5).

Remarque méthodologique : Les variables booléennes (types de prises, options de paiement) ont été encodées en 0/1 pour permettre le calcul des coefficients de corrélation de Pearson.

5 Conclusion

Ce rapport présente les résultats du projet Big Data – Groupe 8. Le pipeline de nettoyage en 4 étapes produit un fichier consolidé de **70 394 points de charge** (sur 184 504 initiaux), prêts pour la visualisation, l’analyse des corrélations et la modélisation prédictive.

L’architecture choisie (scripts modulaires + checkpoints `.rds`) garantit la reproductibilité et la maintenabilité du projet dans le cadre du développement en trinôme avec Git.